TROQUE → TROQUE

Letras trocadas por números no Guardião SMS

Como reconhecer o disfarce sem criar avisos falsos para idosos

João Pedro de Souza Cruz
Instituto Mauá de Tecnologia · Desenvolvimento de aplicativos híbridos

O TCC e o problema

O **Guardião SMS** avisa pessoas idosas quando um SMS pode ser golpe. O modelo BERTimbau roda **dentro do celular**: nada sai do aparelho.

Além do alerta, o app mostra **pontos de atenção**: dicas que procuram palavras como “bloqueada”, “senha” e “dinheiro”.

Escrito com números no lugar das letras, o golpe passa sem nenhuma dica.

SMS REAL DO DATASET DO TCC

```
lTAU: Voce tem 72.103 pontos
vencendo hoje! Troque por DlNHElRO
acesse: https://app.va
```

Outros: TR0QUE · PONTO$ · CAlXA · VENCIMENT0

PERGUNTA DE PESQUISA

Como uma função de normalização, testada com jest-expo, faz as dicas reconhecerem “TROQUE” e “bl0qu3ada” sem criar avisos falsos em mensagens legítimas cheias de números?

Restrição: para um idoso, um aviso falso ensina a ignorar os avisos. Rastreio, valores, datas e “5GB” não podem ser marcados.

Alternativas consideradas

Opção	Funciona no Expo Go?	Decisão
Função própria + jest-expo	Sim, é só JavaScript	Escolhida. Cabe no prazo, roda no aparelho e é verificável
BERTimbau no Expo com onnxruntime-react-native	Não, exige development build	Agora não. Modelo de 105 MB e tokenizador a portar
Enviar ao Hugging Face com fetch	Sim	Descartada. A mensagem sairia do celular (LGPD)

Fontes: Expo, “Unit testing with Jest” e “Introduction to development builds”.

Como funciona



Converte quando

- tem 2 letras ou mais e algum 0 1 3 4 5 7 @ $
- tem mais letras do que trocas
- números seguidos ficam entre letras: bl0qu34d0

Fica igual

`US$ · 5GB · @loja · MXRF11 · COVID19 · TJ152828943BR · links`

Demonstração no celular

1 Golpe disfarçado: **4 pontos de atenção**

2 Chave desligada: cai para **1 ponto**

3 Golpe real com PONTO$

4 Disfarce pesado: bl0qu34d0

5 Mensagem legítima: **nenhum aviso**

6 Campo vazio: botão desabilitado

```
npm run test:ci
```

58 testes passando

```
avaliar-dataset.ts · 3.396 SMS
```

12 golpes · 0 legítimas

ONDE A IA ERROU

Os testes passavam. Os dados reais, não.

Versão da regra	Quem	Testes	Legítimas marcadas
1ª: converte tudo com letras e trocas	Claude	41 passando	8 (US$, 5GB, @perfil)
2ª: exceções de moeda, unidade e perfil	Claude	48 passando	0
3ª: números seguidos com 4+ letras	Copilot	54 passando	2 (MXRF11)
4ª: números seguidos só entre letras	Copilot	58 passando	0

Os testes foram escritos pela mesma IA que escreveu a regra: só cobriam o que ela imaginou.

Medido nas 3.396 mensagens do dataset_v7 do TCC com scripts/avaliar-dataset.ts.

O que mais as IAs erraram

GEMINI

"O Jest é nativo do Expo."

Não é: precisa instalar jest-expo, jest e @types/jest.

CHATGPT

Para retreinar em Python, indicou a documentação do Transformers.js.

É a biblioteca JavaScript. O treino usa o Transformers do Python.

GEMINI × CHATGPT

Mudar o tokenizador ou manter o do treino?

Manter: o do app é idêntico ao do Hugging Face em 3.408 de 3.408 SMS.

A COMPARAÇÃO REVELOU

`5eu c4r74o f01 bl0qu34d0`

O exemplo do Gemini passava sem nenhuma dica e motivou as versões 3 e 4.

Próximos passos no TCC

O que fazer

Levar a regra para o Kotlin, junto do ponto de texto disfarçado que já existe. Os 58 casos viram testes JUnit.

Testar o BERTimbau com e sem a conversão. Esta prova de conceito testou as dicas, não o modelo.

Limites que sobraram

- “1” pode ser “i” ou “l”: a regra escolhe “i”
- Marcas com número viram texto: R7Bet
- Tantas trocas quanto letras passam: 4pr0v4d0
- 8, 9 e “|” não são tratados

Fontes

Expo. Unit testing with Jest. docs.expo.dev/develop/unit-testing

Expo. Introduction to development builds. docs.expo.dev/develop/development-builds/introduction

React Native. Accessibility. reactnative.dev/docs/accessibility

Guardião SMS. AttentionPointsDetector.kt, OnnxClassifier.kt e dataset_v7.csv

Repositório: github.com/Pitucooh/guardiao-poc